

Visual RAG：面向视频检索的自主视觉搜索智能体

张震宇——硕士学位论文（草稿）

摘要

视频被广泛记录，却仍难以按具体时刻检索，尤其当查询表达因果或时序意图时更是如此。本文提出 Visual RAG：一个智能体式检索增强生成系统。系统为带时间戳的视觉与转录证据建立索引，将问题分解为更适合检索的描述，搜索并重排候选视频片段，最后生成带时间戳依据的回答。我们在 NExT-QA 与 NExT-GQA 的 567 个视频、3,358 个带时序标注的问题上进行评估。结果表明，视觉检索显著优于转录文本检索；SigLIP 与查询分解将语料库范围的 R@1 从 0.026 提升至 0.048。LangGraph 智能体将五选一问答准确率从 0.447 提升至 0.547，而加入视觉证据后，时序问题准确率从 0.341 提升至 0.636。实验进一步区分了召回、排序精度与证据传递三个独立瓶颈，并为消费级硬件上的视频 RAG 提供了可复现的设计依据。

目录

第一章 绪论	2
第二章 研究背景与相关工作	5
第三章 系统设计	8
第四章 实现	15
第五章 评估	18
第六章 讨论	27
第七章 结论与未来工作	30
参考文献	32

第一章 绪论

1.1 研究动机

视频已成为日常生活、教育与工作中占主导地位的记录媒介,却仍是最难被检索的媒介。文本搜索以“答案”为粒度:一次查询返回包含答案的句子或段落。而视频搜索在实践中仍以“容器”为粒度:一个标题、一段简介,至多是一条人工分章的时间轴。用户真正想问的问题——男孩为什么把礼物拿到沙发上?狗走到垫子旁之后做了什么?——是关于某几秒画面的问题,且往往以因果、时序的语言表述,这既非元数据上的关键词匹配、亦非语音转写检索所能解决。凡是视频积累速度超过观看速度的场景,都能感受到这一缺口:个人影像库、课程存档、会议录像、广播素材,以及推动本项目立项的工业级视频智能平台。

近年来两条研究线索的进展使这一缺口变得可以弥合。其一,对比式视觉-语言模型 (CLIP 及其后继者) 将图像与自然语言嵌入同一空间,使“画面上有什么”可以直接用文字描述来检索。其二,检索增强生成 (Retrieval-Augmented Generation, RAG) 展示了大语言模型 (LLM) 如何借助检索到的证据回答其自身无法回答的问题——而在视频场景下,检索单元自然应当是带时间戳的片段而非文档。两条线索的交汇处存在一个尚未充分探索的组合:一个智能体式 (**agentic**) 系统,能够分解因果或时序问题、检索视频片段的多模态索引、对检索结果进行推理——包括沿时间轴的推理——并合成一个每条论断都引用其对应视频秒数的答案。

本文在刻意克制的算力预算下 (一台消费级笔记本 GPU 加通用 LLM API), 端到端地设计、构建并评估了这样一个系统,并在带有时序真值标注的基准上,对其每一项设计决策进行了定量检验。

1.2 研究问题

项目计划确定了三个研究问题, 本文将在第五章逐一回答:

- **RQ1** ——与纯文本检索基线相比, Visual RAG 流水线从自然语言查询中检索相关视频片段的效果如何?

- **RQ2** ——多模态视频表征 (视觉 + 音频 + 文本) 的最优嵌入策略是什么?
- **RQ3** ——智能体框架如何自主地将复杂查询分解为子检索任务并合成连贯的答案?

时序精度在全文中被视为一等要求而非附带产物: 检索的评分标准不是找对视频, 而是找对时刻 (以检索片段与真值区间的时序交并比 tIoU 度量); 生成的答案必须携带时间戳引用。

1.3 研究贡献

本文做出五项贡献, 分别在所注章节展开, 并在第五章获得实证支撑:

1. 一条端到端、可公开复现的视频 **RAG** 流水线, 具备时序定位能力 (第三章): 摄取 (关键帧、Whisper 语音识别)、重叠时序分段、联合视觉-语言空间中的双模态索引、分阶段检索, 以及带逐条时间戳引用的回答智能体——在 NEX-T-QA/NEX-T-GQA 的 567 个视频、3,358 个带时序标注的问题上完成评估, 且可在一块消费级 GPU 加约 5 美元 API 费用内端到端运行。
2. 对多模态嵌入策略的系统消融 (第 5.3 节), 包含两个附带因果分析的负结果: 在本领域数据上, 视觉与转写嵌入的加权后期融合在任何权重下都不优于纯视觉检索; 文本交叉编码器重排则严格降低排序质量。两者可追溯至同一成因——日常视频中稀疏、多语言、闲聊式的语音是糟糕的检索键——并共同将改进方向引回视觉通道。
3. 两阶段检索的等价性发现 (第 5.3.4 节): 用更强的视觉骨干模型对廉价索引的 top-30 候选重排, 与用该骨干模型索引整个语料库的效果相当 (差异在测量噪声之内); 而将索引直接换为 SigLIP 使 top-1 时刻检索接近翻倍——两者合起来给出了一份质量与成本可独立缩放的、经过实测的配方。
4. 带时序工具与有界自我反思的智能体回答层 (第三章、第 5.4 节): 一个 LangGraph 状态机, 通过搜索锚定事件、沿时间轴前后游走、并在作答前将草稿引用与已收集证据比对审计, 将五选一 QA 准确率从 .447 提升至 .547; 并通过一个控制其余全部变量的证据通道对照实验证明: 向回答模型提供关键帧, 使“接下来发生了什么”类问题的准确率接近翻倍 (.341 $\rightarrow$.636)。该实验表明, 模态在流水线的两端各自独立地发挥作用。
5. 可复现的研究工件: 完整代码库、评估框架、逐实验结果文件、将每个报告数字映射到产生它的命令的溯源日志、生成图表, 以及一个控件与消融维度一一对应的交互式演示界面。

1.4 论文结构

第二章综述研究背景: 对比式视觉-语言预训练、视频时刻检索及其基准、检索增强生成, 以及智能体式 LLM 框架。第三章给出系统设计及每项决策的理由。第四章记录实现: 具体技术栈, 以及在既定预算内跑通全流水线所需的工程。第五章——本文的核心——针对三个研究问题评估系统。第六章讨论结果的含义、局限与效度威胁。第七章总结并展望未来工作。

第二章 研究背景与相关工作

本章综述本系统所组合的四条研究线索——对比式视觉-语言预训练 (§2.1)、视频时刻检索及其基准 (§2.2)、检索增强生成 (§2.3) 与智能体式 LLM 框架 (§2.4)——继而考察与本项目同样将它们组合为 LLM 驱动的视频理解系统的新兴工作 (§2.5), 最后陈述本文所回应的研究空白 (§2.6)。引用键对应 `references.bib`。

2.1 对比式视觉-语言预训练

CLIP(Radford et al., 2021) 确立了这样一个事实: 以对比目标在网络规模的图文对上训练的双编码器, 可以产生一个联合嵌入空间, 使任意自然语言描述能够零样本地与图像匹配。该模型族的两个性质支撑了本系统。其一, 双编码器架构将图像编码与文本编码分离, 因此语料库可以离线一次性嵌入, 之后仅用 (廉价的) 文本塔进行查询——这是第三章离线/在线分工的架构前提。其二, 由于训练数据是替代文本 (alt-text) 式的图片说明, 编码器最擅长匹配字面的场景描述; 抽象、因果或时序性语言落在其训练分布之外, 本项目在查询期 (§3.4) 而非通过微调来弥合这一错配。

围绕 `open_clip` 的开源复现工作证明了该模型族可复现的缩放规律, 并发布了本文使用的 LAION 训练权重 (Schuhmann et al., 2022; Cherti et al., 2023)。SigLIP(Zhai et al., 2023) 以成对的 sigmoid 损失替代 CLIP 基于 softmax 的 InfoNCE 目标, 去除了对整个批次的全局归一化, 在相当规模下取得显著更强的检索性能。第 5.3.4 节的骨干模型消融——SigLIP SO400M 作为索引使 top-1 时刻检索相对 CLIP ViT-B 接近翻倍——在日常视频上、以时序定位为标准, 独立复现了这一优势。

2.2 视频时刻检索、视频问答与时序定位

文本到视频的检索最初以整段视频为粒度, 代表性基准如 MSR-VTT(Xu et al., 2016); CLIP4Clip(Luo et al., 2022) 表明, 帧级 CLIP 特征经池化后, 几乎不需要视频专用组件即可迁移到该任务——本系统在片段级采用的正是同样的“以帧代视频”假设。时刻检索将任务细化为在视频内部定位一个区间: Gao et al.(2017) 提出了滑动窗口的问题形式与 Charades-STA 数据集;

密集事件描述随 ActivityNet Captions(Krishna et al., 2017) 出现;Moment-DETR(Lei et al., 2021) 将定位重述为端到端的集合预测。本系统继承滑动窗口形式——其 8 秒重叠片段就是以嵌入相似度打分的窗口——但执行的是语料库级时刻检索 (在 567 个视频中找到那个时刻), 而时刻检索文献通常假定“找视频”已由上游解决。

在问答一侧,NExT-QA(Xiao et al., 2021) 将视频问答从描述性问题推进到因果与时序问题——为什么与接下来发生了什么——领域为日常视频。其扩展 NExT-GQA(Xiao et al., 2024) 补充了 10.5K 条时序定位标注, 并报告了一个发人深省的发现: 最先进的视频-语言模型能答对问题, 注意力却落在错误的时刻上, 亦即答案的视觉根据薄弱。这一发现同时决定了本文的基准选择与评估设计:NExT-GQA 的区间标注使检索得以在时刻粒度 (tIoU) 而非视频粒度上评分; 而答案的可溯源性——每条论断引用其秒数——被作为一等输出要求而非诊断指标。SeViLA(Yu et al., 2023) 通过在单一训练模型内串联定位器与回答器来解决定位问题; 本系统以智能体编排零样本组件, 达成类似的“先定位、后回答”分解, 而无需端到端训练。

2.3 检索增强生成

RAG 将参数化语言模型与非参数化检索索引耦合 (Lewis et al., 2020; Guu et al., 2020), 经典形式基于稠密段落嵌入 (Karpukhin et al., 2020)。三个反复出现的 RAG 子问题在本文中以视频形态再现。

查询-文档错配。当查询与被索引内容处于不同语域时, 改写查询是有效的:HyDE(Gao et al., 2023) 生成一份假设文档并以其嵌入进行检索;least-to-most 提示 (Zhou et al., 2023) 将复杂问题分解为更简单的子问题。W5 分解器 (§3.4) 将这一思想跨模态迁移:LLM 把因果问题改写为对比式视觉编码器能够匹配的场景描述语域——这正是 HyDE 的手法, 只是“文档”换成了“图片说明”。多个改写用倒数排名融合 (Reciprocal Rank Fusion, RRF;Cormack et al., 2009) 合并, 其基于排名、与分数无关的形式正是安全融合措辞各异的子查询的关键。

排序头部的精度。以交叉编码器为第二级的“检索-重排”两阶段流水线是文本检索的标准做法 (Nogueira and Cho, 2019),BGE 系列 (Chen et al., 2024) 是最强的开源重排器之一。第五章表明这一迁移在视频上并不自动成立: 文本交叉编码器在日常视频上反而降低排序质量, 因为转写文本是薄弱的相关性证据 (§5.3.3); 有效的第二级是一个更强的视觉编码器——架构层面的模式相同, 模态不同。

自我批判。Self-RAG(Asai et al., 2024) 训练模型以反思标记批判自身的检索与生成。图智能体的反思节点 (§3.5) 以零样本提示的方式实现同一原则——作答前将草稿与检索证据比对审计——并将其置于显式、有界的控制流位置, 而非训练出的能力。

2.4 智能体式 LLM 框架

思维链提示 (Wei et al., 2022) 确立了中间推理对 LLM 任务性能的提升;ReAct(Yao et al., 2023) 将这种推理与针对外部工具的行动交错, 定义了当下大多数智能体 (包括本项目的两个智能体) 所依赖的“观察-思考-行动”循环。Toolformer(Schick et al., 2023) 证明工具调用可以自监督习得, 预示了商用 LLM API 如今原生提供的函数调用接口——W4 智能体正是直接构建于其上。Reflexion(Shinn et al., 2023) 增加了跨回合的言语自我反馈, 在不更新权重的情况下改进智能体——上文的反思节点是其回合内的对应物。本项目的多步智能体基于 Lang-Graph(LangChain 项目的状态机编排库) 实现, 选择它的原因是它将控制流——节点、有界循环、终止条件——显式化且可审视 (§3.5), 与将循环编码在提示词里、行为隐含于模型输出的做法形成对照。

2.5 LLM 驱动的视频理解与视频 RAG

将 LLM 编排应用于视频的工作正快速增长。LLOVi(Zhang et al., 2024) 展示了一个刻意简单的配方——为短片段密集生成字幕, 再让 LLM 聚合字幕——在包括 NExT-QA 在内的长视频问答上表现强劲。两个同名的 VideoAgent 系统让 LLM 成为主动控制器:Wang et al.(2024) 迭代地搜索信息量最大的帧, 平均仅用约 8 帧回答 NExT-QA;Fan et al.(2024) 为 LLM 配备了关于事件与物体轨迹的结构化记忆, 通过工具查询。VideoRAG(Ren et al., 2025) 以图组织的索引将 RAG 框架扩展到超长多视频语料。本系统属于这一家族, 但在三个方面侧重不同。第一, 时序定位即交付物: 检索以 NExT-GQA 区间的 tIoU 评估, 答案必须引用时间戳, 而上述系统仅报告 QA 准确率。第二, 本系统工作于语料库范围——问题并不指明其所属视频, 找到视频本身是任务的一部分。第三, 本文的贡献是测量: 一套逐组件的消融方案 (模式、融合、分解、重排、骨干模型、证据通道), 含有记录在案的负结果, 而非一个新模型或一次榜单登顶。

2.6 研究空白小结

本项目的每一个组成部分都已各自成熟: 零样本视觉匹配的对比式编码器、滑动窗口时刻检索、RAG 的“检索-改写-重排”工具箱、ReAct 式工具智能体, 以及 LLM 视频编排。文献所缺——且 NExT-GQA 的定位发现 (Xiao et al., 2024) 表明实践中确实缺失——的, 是一份关于这些组件如何组合成一个时序定位可靠的、语料库级的视频 RAG 系统的论述, 其中每个组件的贡献在同一协议下被测量, 包括标准组件在何处迁移失败。在可复现的消费级基础设施上提供这份论述, 正是第三至六章的任务。

第三章 系统设计

本章描述 Visual RAG 系统的设计, 并为每个组件说明其设计选择背后的理由。整体架构由一个刻意设定的约束和一项方法论承诺塑造。约束是: 在线系统必须运行在消费级硬件 (6 GB 显存的笔记本 GPU) 上——所有重计算被推入一次性的离线索引阶段, 每次查询只触及一个文本编码器、一个近似最近邻索引和一次 LLM API 调用。承诺是: 每个检索组件都应当可独立测量——模态分开索引、流水线阶段可开关, 第四、五章新增的每个组件 (分解、重排、时序工具、反思) 都能在不触碰其余部分的情况下启用或停用。这正是第五章消融方案得以成立的原因, 下文若干设计选择的首要理由即在于此。

3.1 架构总览

图 3.1(fig1_pipeline) 展示了系统的两条泳道。离线泳道摄取视频语料并产生一个可携带的索引: 逐视频抽取关键帧与带时间戳的转写, 融合为重叠的时序片段, 嵌入联合视觉-语言空间, 存入向量数据库。在线泳道服务自然语言查询: 查询 (可选地) 被分解为利于检索的子查询, 编码后在索引中搜索, (可选地) 由更强的视觉模型重排, 得到的片段——时间戳、转写与关键帧——作为证据交给回答智能体, 由其产出带逐条时间戳引用的、有据可依的回答。

离线/在线分工不止是工程上的便利。它使昂贵的工件可复用、可携带——567 个视频的索引只有几百兆字节, 可在任何 GPU 上一次算好、随处拷贝; 它也让研究迭代变快: 第五章的每个实验都复用同一份冻结的摄取输出, 因此一次覆盖 3,358 个问题的完整检索评估在笔记本上几分钟即可完成。这一分工同时映照了生产环境中的视频搜索架构: 索引吞吐与查询延迟本就是两本预算。

3.2 摄取与时序分段

关键帧。每个视频只解码一遍, 由两种互补策略采样: 镜头边界检测 (PySceneDetect 自适应检测器) 为每次场景切换贡献一帧代表帧; 0.5 fps 的均匀采样保证不触发切换的长静态镜头也有覆盖。时间戳按最小 1 秒间隔去重, 每视频上限 64 帧 (超限时均匀抽取子集); 帧以

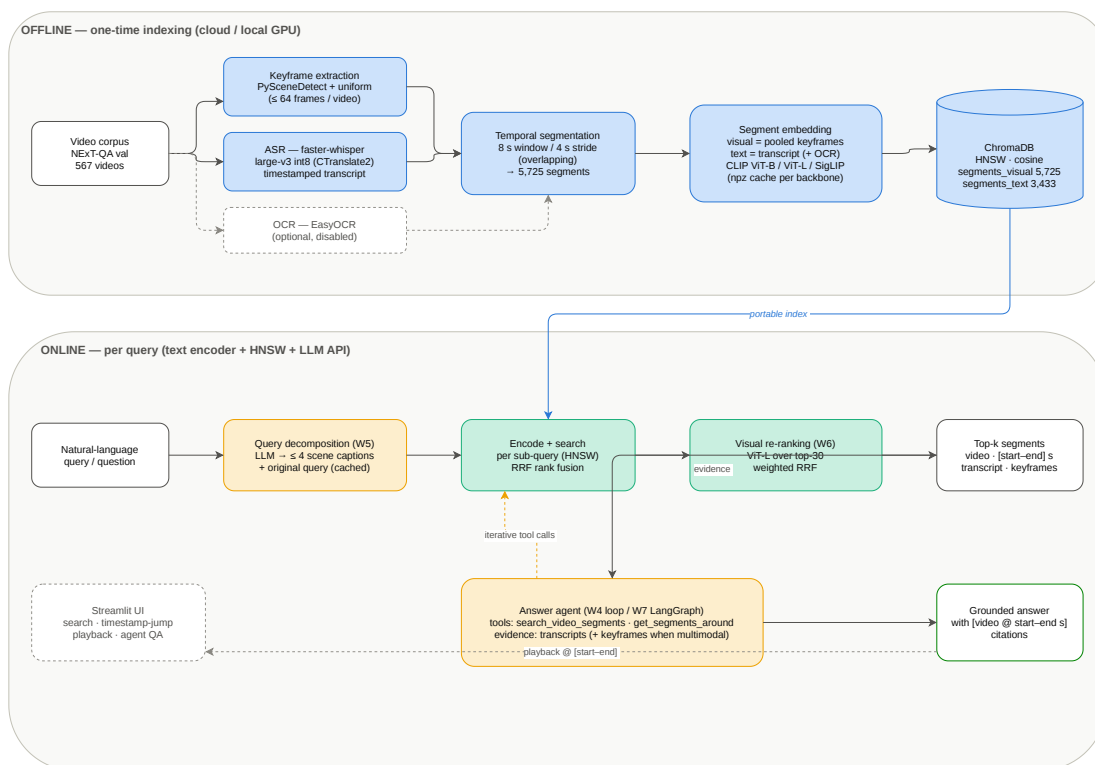


图 3.1: Visual RAG 的离线索引与在线检索流水线。

长边 384 像素的 JPEG 存储。双策略对应二者各自的失效模式: 场景检测对静态素材采样不足, 均匀采样错过短暂转场。

语音。音频由 int8 量化的 Whisper large-v3 经 CTranslate2 转写, 产出带起止时间戳的句级片段。两个实践中重要的健壮性细节: 其一, 无音轨的视频被预先检测并跳过而非让批处理崩溃——这是用无声测试片段真实踩到的坑; 其二, 语言按视频自动检测而不强制为英语: NExT-QA 的家庭视频是多语言的, 忠实转写 (而非错误地按英语转写) 为将来的“先翻译再嵌入”管线保留了可能性, 代价则是 §5.2 所分析的编码器错配。屏幕文字 OCR 已实现但默认关闭: 基准视频几乎没有可读文字, 该模态可在其收益足以覆盖成本的场景经配置启用。

时序分段。检索的原子单元是片段: 8 秒窗口、4 秒步长推进, 携带落入其中的全部关键帧、与其重叠的转写拼接, 以及精确的 [start, end] 区间。既无帧也无文本的窗口被丢弃; 567 个视频产出 5,725 个片段。三点考虑确定了这些数字。窗口必须足够短, 使“检索到该片段”本身即构成时序精确的回答——8 秒相对 44 秒的平均视频长度, 给出约五倍于整视频检索的细化, 与 NExT-GQA 真值时刻的量级相称。50% 的重叠保证靠近窗口边界的事件在至少一个窗口中完整出现, 代价是近重复的检索结果 (相邻重叠窗口频繁同时出现在头部排名中, 第五章通篇可见, 属良性冗余)。而固定窗口——相对镜头对齐或内容自适应的窗口——使真值到片段的映射保持简单、tIoU 天花板可分析 (§6.2)。片段记录以逐视频 JSONL 持久化, 是摄取与全部下游组件之间唯一的接口。

3.3 嵌入与双模态索引

每个片段在联合视觉-语言嵌入空间中获得至多两个向量。视觉向量是其关键帧 L2 归一化图像嵌入的均值, 再归一化——均值池化是标准且无超参数的聚合方式, 保持余弦几何。文本向量用同一模型的文本编码器嵌入片段转写 (启用 OCR 时并入)。两个模态使用同一联合空间, 才使单次编码的查询能够搜索任一集合; 其代价——已知并接受——是在替代文本上训练的对比式文本编码器读不好长文本或非英语转写 (其 77 token 的上下文会截断长段落), 第五章对此做了量化。

编码器本身置于一层薄接口 (open_clip) 之后, 骨干模型因此是一个配置项: 开发用 ViT-B-32, 消融用 ViT-L-14 与 SigLIP SO400M (第五章)。每个骨干的片段嵌入以逐视频压缩数组缓存在磁盘上, 使换骨干只需一次重嵌入、重建索引只需数分钟——W8 骨干对比之所以负担得起, 正是靠这一性质。

向量存于 ChromaDB——一个嵌入式向量库。选择它而非服务器级方案 (Milvus、Qdrant) 的理由是: 在 10^3 – $10,000$ 个片段的规模上, HNSW 检索实际上等同精确检索, 运维简单性压倒理论可扩展性。两个模态存为独立集合, 共享片段 ID 与元数据 (video_id、start、end、帧数), 而非拼接为单一向量。这是全部索引决策中影响最深远的一项: 集合分离意味着每个模态可以被独立地搜索、打分、评估——恰是 RQ2 消融之所需; 后期融合、前期融合或

任一单模态,都成为同一索引之上的查询期选择。片段文本作为集合的文档载荷随行存储,下游组件(重排器、智能体)无需回读磁盘即可取用。

3.4 检索

检索器暴露唯一一条代码路径,评估框架、智能体与演示界面以完全相同的方式调用——这是刻意为之,使测得的数字描述的就是用户实际交互的系统。

单查询检索用索引骨干的文本编码器编码查询,在单一模态中做余弦检索;或以后期融合(得分 = $\alpha \cdot \text{视觉} + (1-\alpha) \cdot \text{文本}$,融合前按三倍超取候选)同时使用两个模态。选择后期融合而非前期(拼接)融合,是因为它无需联合训练、可按模态平凡地消融,并将 α 暴露为一个可解释的旋钮——§5.3.1 的 α 扫描随后证明这个旋钮在本语料上没有任何有用档位,而这一发现本身正是该设计让它变得廉价可得的。

查询分解(W5)针对因果/时序问句措辞与 CLIP 训练分布(字面场景描述)之间的错配。LLM 将问题改写为至多四条现在时的简短场景描述;每条描述连同原始问题独立检索,排名以倒数排名融合($k=60$)合并。两个承重的设计细节:保留原始问题保证分解只能增加候选、永不替换基线行为——正是这一安全性质使其可默认启用;基于排名(而非分数平均)的融合规避了措辞各异的子查询之间余弦分数不可比的问题。分解结果按问题文本为键缓存于磁盘,3,358 个问题的整个评估的边际成本是一次性的约 0.15 美元。

第二级重排(W6)对 30 个候选重新打分,并以第一级排名与重排器排名的加权 RRF 重新排序。该设计经历了一次记录在案的失败:计划中的文本交叉编码器(问题 $\times$ 转写)降低了全部指标(成因诊断见 §5.3.3),现仅作为消融配置保留。接替它的方案对候选做视觉重打分——用更强的骨干(ViT-L-14)在预计算的片段嵌入上——把重排器变成“一位更好的目击者的第二意见”,而非另一个模态。那次失败沉淀出的一条方法论教训被同时植入两个重排器:当候选缺少重排器的模态(无转写;无缓存向量)时,其重排器名次由检索名次填补而不是视为缺失,使所有候选保持在同一分数尺度上。否则,重排器能打分的候选会结构性地压过一切它不能打分的候选——早期实现正因此把 R@1 悄悄打到了零。

3.5 智能体式回答

回答层将检索到的片段转化为自然语言答案,并以 [video_id @ start-end s] 的形式逐条引用。它构建为基于原生 LLM 函数调用的双工体系,并有两个复杂度递进的执行框架。

工具。 `search_video_segments(query, modality)` 封装检索器;其描述指示模型将查询措辞为场景描述而非问句——把查询分解的洞察压入智能体的工具使用行为。`get_segments_around(video_id, timestamp, direction, n)` 是时序原语:返回某视频中某时间戳之前或之后紧邻的片段。时序问题(“X 之后 Y 做了什么?”)以组合方式回答——

先用搜索锚定 X, 再向 after 方向游走——系统提示词明确陈述了这个两步计划, 且智能体被观察到确实遵循它 (§5.4.1)。

简单智能体 (W4)。一个有界的工具使用循环: 模型至多调用三轮工具, 之后以禁用工具的最终调用强制其基于已收集证据作答。强制作答步骤的存在, 是因为两家 LLM 供应商在放任状态下都会偶尔持续请求搜索直到轮次预算耗尽、然后返回空答案——这是一个早期缺陷, 其修复 (一个显式的“预算耗尽, 立即作答”回合) 同时适用于两个框架。

图智能体 (W7)。图 3.2(fig2_langgraph) 的 LangGraph 状态机加入了线性循环难以干净表达的两件事。第一, 显式的反思节点: 当智能体产出草稿答案时, 一次独立的 LLM 调用将其与实际收集到的证据比对审计——被引用的片段是否存在于工具结果中? 论断是有据可依还是凭空捏造? 相对锚点的时序关系是否正确?——审计通过则接受 (状态机终止), 否则附上批评意见退回一次, 恢复工具循环。反思是有界的 (至多一次修订) 且预算感知的: 只有剩余轮次足以落实批评时才请求修订——这道防线源自一次“预算耗尽的修订死循环”的观察。第二, 状态机使控制流可审视: 每次运行产出一份轮次、工具调用与反思的类型化轨迹, 第五章的定性分析正是基于它。

W7 LangGraph answer agent — ReAct loop with bounded self-reflection




图 3.2: 带工具调用与有界反思的 LangGraph 回答智能体状态机。

供应商抽象与证据通道。两个智能体都可运行于 OpenAI 兼容端点 (DeepSeek; 或任何本地服务如 Ollama) 或 Anthropic API。这层抽象不止是运维意义上的: 两类供应商在证据通道上不同。多模态供应商下, 工具结果将每个片段的中间关键帧作为图像块与转写并列嵌入 (每次结果至多六张); 纯文本供应商下, 同一渲染器只输出转写与时间戳。由于工具、提示词与检索在两类供应商间完全一致, 切换供应商即是对“回答者能感知何种证据”的受控操纵——正是这一设计性质, 使 §5.4.2 的证据通道实验得以作为真正的单变量对照进行。

3.6 演示界面

一个 Streamlit 应用以两个标签页交互式地暴露完整流水线。检索页运行检索栈, 组件逐一可开关——模态、查询分解、视觉重排——每条命中渲染关键帧、时间戳、转写与分数; 展开某条命中即播放源视频并直接跳转到片段起点, 把”自然语言查询 → 屏幕上那一刻”的回路闭合。问答页在任一供应商下运行任一智能体, 展示答案及其完整证据轨迹 (每次工具调用及其返回的片段)。这些开关与第五章的消融维度一一对应; 该界面因此兼具研究仪器——第五、六章引用的定性观察都经由它得出——与项目可演示工件的双重身份。




图 3.3: Visual RAG 演示界面的检索结果与带时间戳证据。

3.7 小结

本设计将赌注押在廉价、可测量的组件上而非端到端训练: 固定重叠片段作为时序定位单元; 单一联合嵌入空间、模态分开索引; 检索改进 (分解、重排) 以纯查询期重排序的方式组合; 智能体层的工具、控制流与证据通道各自独立可切换。第四章详述这些组件的实现; 第五章对其进行测量。

第四章 实现

第三章描述了造了什么以及为什么; 本章记录怎么造的, 重点是使一次完整基准评估能够在单台消费级笔记本 (RTX 4050, 6 GB 显存) 加几美元 API 费用内完成的工程。代码库是一个小型 Python 包 (`visualrag/`), 配以轻薄的命令行入口 (`scripts/`)、每个实验条件一份 YAML 配置, 以及一个 Streamlit 界面 (`ui/`)。

4.1 技术栈

事项	选型	备注
视频解码 / 时长	PyAV	每视频单次解码
镜头检测	PySceneDetect(自适应)	+ 0.5 fps 均匀兜底
语音识别	faster-whisper(large-v3,int8)	CTranslate2 运行时
嵌入	open_clip:ViT-B-32、ViT-L-14、SigLIP SO400M	一套接口, 三个骨干
向量库	ChromaDB(嵌入式,HNSW, 余弦)	每骨干两个集合
重排器 (消融)	sentence-transformers bge-reranker-v2-m3	文本交叉编码器,§5.3.3
智能体框架	LangGraph	W7 状态机
LLM 供应商	DeepSeek、Anthropic Claude、任意 OpenAI 兼容端点	供应商无关的回答器
界面	Streamlit	检索 + 时间戳跳转播放
评估	自研框架 (<code>visualrag/eval</code>)	§5.1 全部指标

两个选型各值一句话。选 ChromaDB 而非服务器级向量库, 是因为在 10^3 – $10,000$ 向量规模上 HNSW 实际等同精确检索, 零运维压倒理论可扩展性。选 LangGraph 而非更重的智能体框架, 是因为 W7 设计恰好只需要一样东西——一个显式、有界、可审视的状态机——别无其他。

4.2 把流水线塞进 6 GB

计划的前提 (§3.1) 是重计算发生在离线阶段; 实现的贡献是让“离线”在本地就负担得起, 而不必依赖云 GPU。三项技术起了作用。

将 **ASR** 与深度学习运行时解耦。Whisper large-v3 在 PyTorch 下名义上超出 6 GB 预算, 但 faster-whisper 通过 CTranslate2 以 int8 权重运行, 仅需约 3 GB。一个集成细节曾付出一次缺陷修复的代价: 流水线的设备自动探测最初查询的是 *PyTorch* 的 CUDA 可用性——在 CPU 版 PyTorch 下即使 GPU 可用也返回否——因此转写器改为直接探测 CTranslate2 自身的 CUDA 设备数, 并在 Windows 上将 pip 安装的 cuBLAS/cuDNN 库注入 DLL 搜索路径。就位之后, 567 个视频的完整语料在本地约 2 小时转写完毕。

以嵌入缓存为复用单元。每个骨干的片段嵌入以逐视频压缩数组 (.npz) 持久化, 以片段 ID 为键。建索引只读缓存; 评估只读索引。因此任何实验的复跑只需数秒; 新增一个骨干只需一次嵌入; 视觉重排器 (§3.4) 在查询期除一次矩阵乘外零成本——它的 ViT-L 向量与 ViT-L 索引消融用的是同一份缓存。一个相关的健壮性细节: SigLIP 在 open_clip 中的实现不暴露 visual.output_dim, 编码器封装因此以三级探测 (属性 → 模型字段 → 一次哑元前向) 解析嵌入维度——“一套接口, 三个骨干”的承诺实际依赖的正是这类小修补。

处处幂等。每个批处理阶段——摄取、嵌入、建索引、分解——都检查自身输出、跳过已完成的工作, 粒度为单视频或单问题。笔记本上的长任务一定会被打断 (休眠、内存不足、会话重置); 阶段幂等之后, 每次重启都从中断处续跑。项目期间这一点被反复检验: 全语料摄取经历两次进程被杀, 最终在一个自愈看门狗脚本 (反复重启批任务直至完成标记出现, scripts/ingest_watchdog.ps1) 下完成。

4.3 面向 LLM 组件的成本工程

两个流水线组件调用 LLM API; 二者的工程目标一致: 评估规模永不放大 *API* 成本。

查询分解的结果以问题字符串为键缓存于磁盘。整个验证集 (3,358 个问题, 16 路并发) 只花费约 0.15 美元一次; 此后每个实验——W5/W6/W8 消融各自多次复跑依赖分解的检索——都免费重放缓存。该缓存已提交入库, 使检索实验无需任何 API 密钥即可确定性复现。

智能体评估以线程池批量处理问题 (检索栈只读、线程安全), 从固定的哨兵行解析模型的最终选项, 并记录逐问题的 token 用量。150 题的智能体对比花费约 0.35 美元 (DeepSeek); 44 题的多模态运行约 3 美元 (Claude)。对速率限制的尊重通过限制并发实现, 而非重试风暴。

4.4 供应商无关的回答器及其陷阱

回答器可不加修改地运行于 Anthropic API、DeepSeek 或任意 OpenAI 兼容端点 (含本地 Ollama 服务——留作未来工作的开源模型对比正是经此挂钩)。抽象层很薄: 每个供应商族一个消息格式适配器、一套共享工具模式、一个共享证据渲染器 (供应商支持视觉时附加关键帧图像块)。实战贡献了三处值得记录的修复——每一处的症状都是静默产出空答案或损坏答案而非报错。(i) 模型有时会把整个轮次预算花在持续请求搜索上; 循环必须以一个禁用工具的强制作答回合收尾。(ii) 在强制作答回合下, DeepSeek 偶尔会把它本想发出的工具调用以字面标记写进消息正文; 答案提取器需将其剥离。(iii) 当自我反思可以将智能体退回去补充证据时, 修订路径必须检查剩余轮次预算, 否则“反思-行动”循环会将预算耗尽、状态机无答案而终。

4.5 评估框架与数字溯源

评估框架 (`scripts/evaluate.py`、`scripts/eval_qa.py`) 将第五章的每个实验维度暴露为旗标 (`--scope`、`--modalities`、`--tau`、`--decompose`、`--rerank`、`--agent`、`--provider`), 配合逐条件的 YAML 配置, 每次运行输出一份自描述 JSON。全部结果文件提交于 `results/`; docs/EXPERIMENTS.md 将本文报告的每个数字映射到产生它的确切命令、配置与日期; 论文的数据图由一个已提交的脚本 (`docs/figures/make_figures.py`) 从这些 JSON 生成——因此没有任何报告数值只存在于行文之中。图 3.1–3.2(架构图) 以可编辑的 draw.io 源文件连同导出稿一并维护。

4.6 小结

实现的主线是复用: 每视频一次解码、每骨干一次嵌入、每个独立问题一次 LLM 调用、评估框架/智能体/界面共用一条代码路径。正是这种纪律——甚于任何单项优化——使一套论文规模的评估方案 (二十余次全集检索运行、三项智能体研究、三个骨干) 得以在一台笔记本上、一周之内执行完毕。

第五章 评估

本章针对三个研究问题评估系统。§5.1 描述全部实验共享的实验设置。§5.2 以多模态检索对纯文本基线的比较回答 RQ1。§5.3 以一系列针对嵌入与检索策略的消融回答 RQ2——模态融合、查询分解、第二级重排与嵌入骨干——其中包含两个塑造了最终设计的负结果。§5.4 以智能体流水线的端到端问答准确率回答 RQ3, 并以一个分离“视觉证据在回答阶段的贡献”的对照实验收束。§5.5 报告系统级开销。本章所有数字均可由已提交的结果文件 (results/*.json) 复现; 产生每个结果的确切命令记录于 docs/EXPERIMENTS.md。

5.1 实验设置

数据集。全部实验使用 NExT-QA(Xiao et al., 2021) 的验证集——一个针对约 44 秒日常视频的因果/时序多项选择问答基准——并配合 NExT-GQA(Xiao et al., 2024) 贡献的时序定位标注。该集合含 567 个视频上的 3,358 个问题, 与定位标注求交后, 每个问题都携带至少一个标示其答案证据位置的真值时间区间。选择 NExT-GQA 而非更大的检索基准 (如 MSRVT、ActivityNet Captions), 正是因为这些区间标注使检索能够以时序精度评分, 而非整视频粒度。

索引。第三章的摄取流水线从 567 个视频产出 5,725 个重叠片段 (8 秒窗口、4 秒步长)。每个片段被索引进两个 ChromaDB 集合 (HNSW, 余弦): 视觉集合存放片段关键帧池化后的 CLIP 嵌入 (5,725 个向量), 文本集合存放其语音转写的 CLIP 文本嵌入 (3,433 个向量——60% 的片段含语音)。除非另有说明, 索引骨干为 CLIP ViT-B-32(laion2b); §5.3.4 变换骨干。

检索指标。对每个问题, 以问题文本为查询检索 top-K 片段。当且仅当检索片段来自真值视频且其时间区间与某一真值区间的 $\text{tIoU} \geq \tau$ 时计为一次命中; 双条件将指标锚定在时刻级检索而非视频识别。我们在主阈值 $\tau = 0.5$ 下报告 $\text{Recall}@ \{1, 5, 10\}$ 与 MRR; 报告以分级 tIoU 增益计算、按真值视频自身片段做理想归一化的 $\text{nDCG}@10$; 以及 $\text{tIoU}@1$ ——排名第一片段的平均时序重叠, 即本文的“时序精度”度量。§5.3.5 在更宽松的 $\tau = 0.3$ 下复跑关键配置。

检索范围。评估两种范围。**corpus**(全库) 范围下, 查询在 567 个视频的全部 5,725 个片段中检索——这是完整的 RQ1 设定, 系统必须同时找对视频与找对时刻。**video**(视频内) 范围将检索限制在真值视频自身的片段中, 分离出纯粹的时序定位能力。两种范围之间的差距, 将误差归因于跨视频混淆抑或视频内不准。

问答指标。§5.4 直接在 NExT-QA 的五选一格式上评估答案生成: 智能体收到问题及其五个选项, 用工具收集证据, 最终必须输出选项序号。准确率按总体与问题类型分别报告 (CW/CH: 因果为什么/如何; TN/TC/TP: 时序之后/当时/之前)。随机猜测的下限是 0.20。

实现常量。除被消融变动者外: 融合权重 $\alpha = 0.5$, 检索深度 $K = 10$, 重排候选池 30, 问题编码器与索引骨干一致。给定已提交的分解缓存, 全部检索实验是确定性的; 智能体实验使用默认温度的 API 调用, 因此存在正常的 LLM 方差。

5.2 RQ1 ——多模态检索对纯文本基线

表 5.1 报告 $\tau = 0.5$ 下三种单策略配置在两种范围的结果。纯文本基线将每个片段的 Whisper 转写嵌入、以问题文本检索——即 RQ1 要求超越的“搜索说了什么”的标准做法。

表 5.1 ——按模态的检索结果 (ViT-B-32 索引, $\tau = 0.5$)。

范围	模态	R@1	R@5	R@10	MRR	nDCG@10	tIoU@1
corpus	视觉	.026	.075	.111	.047	.117	.035
corpus	文本	.002	.005	.011	.004	.011	.003
corpus	融合 ($\alpha=.5$)	.002	.010	.013	.005	.018	.007
video	视觉	.148	.394	.491	.250	.659	.203
video	文本	.080	.232	.305	.143	.390	.117
video	融合 ($\alpha=.5$)	.129	.384	.491	.235	.639	.186

三点观察回答了 RQ1。第一, 在全库范围, 视觉检索以一个数量级压倒文本检索 (R@10 为 .111 对 .011): 要在 567 个日常视频中找到一个时刻, 画面上是什么远比说了什么更具区分力。第二, 文本通道的失败有可识别的成因, 并非转写质量的伪影: NExT-QA 的家庭视频语音稀疏、口语化且常为非英语 (转写中出现德语、汉语等), 而同时嵌入查询与转写的 CLIP 文本编码器主要以英语替代文本训练。更根本地, 信息常常根本不在语音里——关于小孩做了什么的问题, 很少由任何人说的话回答。第三, corpus/video 的差距定位了困难所在: 在正确视频内部, 系统已能为 39% 的问题把正确时刻排进前五; 而放到全库, R@10 跌至 11%——跨视频混淆而非视频内不准, 才是主导误差, 这正是 §5.3 各项面向精度的干预的动机。

按题型的细分 (附录 B) 显示, 时序精确类问题 (TP, $n = 52$) 在全库范围检索最差, 为 §5.4 的时序推理主题埋下伏笔。

5.3 RQ2 —— 嵌入与检索策略消融

5.3.1 负结果一: 朴素后期融合从未胜过纯视觉

面对一个弱而非零的文本通道, 自然的回应是加权后期融合: 得分 = $\alpha \cdot \text{视觉} + (1-\alpha) \cdot \text{文本}$ 。图 5.1(fig4_alpha_sweep) 在全库范围对 α 属于 {0.5, 0.7, 0.8, 0.9} 扫描。每项指标都朝 $\alpha = 1.0$ 端点——纯视觉——单调上升, 却无一越过它; video 范围同理: 最好的融合配置 ($\alpha = 0.8$) 在 R@10 上与纯视觉打平 (.494 对 .491), 却在 R@1(.139 对 .148) 与 MRR(.244 对 .250) 上落败。 $\alpha = 0.5$ 时融合在全库范围是灾难性的 (R@10 .013), 因为文本分数是叠加在微弱但真实的视觉信号上的高方差噪声。




图 5.1: 全库范围的后期融合权重扫描。

结论比“调 α ”更锋利: 在当前文本通道下, 不存在任何权重使转写嵌入贡献正向证据。融合不是权重问题而是通道质量问题——可行的推论是先修复文本通道 (如先将转写翻译为英语再嵌入, 或换用专门的多语言文本检索编码器) 再重新引入, 而不是继续搜索权重空间。此后全部实验均采用视觉模态。

5.3.2 查询分解: 召回更多, 却未更准

NExT-QA 的问题是因果与时序式的 (“男孩为什么从一堆礼物里拿起一个并走到沙发”), 而 CLIP 匹配的是字面场景描述。W5 分解器提示 LLM 将每个问题改写为至多四条简短场景描述 (“一个男孩从一堆礼物中拿起一个礼物”、“一个男孩拿着礼物走向沙发”、……), 对每条描述与原始问题各自独立检索, 再以倒数排名融合合并排名。改写按问题一次计算并缓存 (3,358 个问题约合 0.15 美元的 LLM 用量)。

分解提升了全库范围的深排名指标—— $R@10$.111 $\rightarrow$.122(相对 +9.9%)、 $R@5$ +6.7%、 MRR +6.4%——而 $R@1$ 与 $tloU@1$ 不变 (表 5.2 第 1–2 行; 图 5.2)。这一模式富有信息量: 把抽象问题翻译成 CLIP 原生的场景描述, 使更多正确候选浮入前十, 但近乎并列的余弦分数经排名融合仍无法把它们推到第一位。召回问题与精排问题是可分离的; 分解解决的是召回问题, 下一节补上缺失的精度。

5.3.3 第二级重排: 一负一正

文本交叉编码器 (负结果)。项目计划预设了标准的文本交叉编码器重排 (bge-reranker), 对候选池的 (问题, 转写) 对打分。在 100 题的开发子集上, 它在所测试的每个融合权重下都降低了质量——权重 0.5 时 $R@5$ 腰斩 (.070 $\rightarrow$.030), 即使 0.8 仍低于不重排的基线。机制与 §5.3.1 同源: 转写是与问题所问视觉事件基本无关的闲聊, 交叉编码器的每次调序都在注入噪声。一个实现上的微妙之处加剧了问题, 值得记录: 40% 的片段完全没有转写, 若这类候选简单地不获得重排分数, 则任何被交叉编码器青睐的有分候选都会压过所有无分候选——恰恰结构性地降权了最可能正确的纯视觉片段。(我们的第一版实现正有此缺陷, 曾把 $R@1$ 打到零。) 修复后的设计将缺失模态候选的重排项由其检索名次填补, 使两类候选保持在同一分数尺度; 上述负结果是在修复后测得的, 因此反映的是通道本身而非缺陷。

视觉重排器 (正结果)。接替方案用更强的视觉模型 (CLIP ViT-L-14) 在预计算的片段嵌入上对 top-30 候选重新打分, 并以加权 RRF 将 ViT-L 排名与第一级排名融合。每个片段都有关键帧, 缺失模态问题随之消失。表 5.2 与图 5.2(fig5_ablation_ladder) 展示 $\tau = 0.5$ 、全库范围的阶梯:

Retrieval ablation ladder — corpus scope, visual modality ($tloU \geq 0.5$)




图 5.2: 从基线到最终配置的检索消融阶梯。

表 5.2 ——全库范围消融阶梯 (视觉模态, $\tau = 0.5$)。

配置	R@1	R@5	R@10	MRR	tIoU@1
ViT-B-32 基线	.026	.075	.111	.047	.035
+ 查询分解 (W5)	.025	.080	.122	.050	.035
+ ViT-L 重排 (W6)	.029	.087	.121	.053	.041
+ 两者	.030	.087	.128	.055	.040
SigLIP 索引 (W8)	.044	.106	.143	.070	.054
SigLIP + 分解	.048	.110	.161	.076	.055

两项中段干预以可加方式组合: 分解贡献于深排名、重排贡献于列表头部, 二者叠加使每项指标都优于基线 (MRR 与 R@10 相对提升 15–17%)。在 video 范围, 组合配置达到 R@1 .154、R@10 .501、tIoU@1 .209——均为 ViT-B 系配置中的最佳。

5.3.4 骨干模型:SigLIP 全面领先, 两阶段追平单阶段

RQ2 的最后一轴替换嵌入骨干本身, 分段与评估保持不变。三个骨干作为索引相互比较: CLIP ViT-B-32(基线)、CLIP ViT-L-14 与 SigLIP SO400M(webli), 各配其自身的问题编码器。

表 5.2(底部两行) 与表 5.3 呈现两个发现。第一, **SigLIP** 对本任务是范畴性的更强: 作为索引, 它使全库 R@1 相对 ViT-B 提升 69%(.026 → .044)、tIoU@1 提升 54%; 叠加分解后达到 R@1 .048——接近初始基线的两倍——以及 video 范围 tIoU@1 .230。这与 SigLIP 的 sigmoid 损失预训练有利于检索任务的报告一致 (Zhai et al., 2023)。

第二, 以 ViT-L 做完整索引 (全库 R@1 .029、R@5 .090、R@10 .122、MRR .054) 与“ViT-B 索引加 ViT-L 重排”(.029/.087/.121/.053) 在统计上不可区分——每项指标的差异都在 ± 0.003 之内。廉价索引/昂贵重排的两阶段设计, 在只用小模型嵌入语料的前提下, 几乎完整回收了大模型的质量; 在更大的语料规模上——用昂贵模型重嵌一切变得不可行时——两阶段设计是通往同等精度的可扩展路径。一条值得向从业者言明的推论: 重排器必须与索引模型不同——用索引自身的嵌入重打分是恒等操作。

表 5.3 ——video 范围骨干对比 (视觉模态, $\tau = 0.5$)。

索引骨干	R@1	R@5	R@10	MRR	tIoU@1
ViT-B-32	.148	.394	.491	.250	.203
ViT-L-14	.151	.407	.496	.257	.210
SigLIP SO400M	.170	.406	.494	.266	.221
SigLIP + 分解	.176	.419	.496	.275	.230

5.3.5 阈值敏感性

对以任意长度真值区间评分的 8 秒窗口而言, $\tau = 0.5$ 是苛刻的判据。表 5.6 在 $\tau = 0.3$ 下复跑 ViT-B 基线与最佳 ViT-B 配置; 二值指标大致翻倍, 而与阈值无关的 tIoU@1 依构造不变。

表 5.6 —— 阈值敏感性 (视觉模态, ViT-B 索引)。

范围	配置	τ	R@1	R@5	R@10	MRR
corpus	基线	0.5	.026	.075	.111	.047
corpus	基线	0.3	.054	.130	.186	.089
corpus	+ 分解 + 重排	0.5	.030	.087	.128	.055
corpus	+ 分解 + 重排	0.3	.062	.151	.208	.101
video	基线	0.5	.148	.394	.491	.250
video	基线	0.3	.311	.660	.774	.456
video	+ 分解 + 重排	0.5	.154	.410	.501	.258
video	+ 分解 + 重排	0.3	.323	.677	.780	.469

两点结论: 系统的实际定位能力 (“落在正确时刻的宽松重叠内”) 远好于严格口径的头条数字——在正确视频内, 三分之二的问题的正确时刻位列前五; 且各配置的相对排序跨阈值稳定, 故上文的消融结论不依赖 τ 的取值。

5.4 RQ3 —— 智能体式问答

5.4.1 智能体对比

表 5.4 与图 5.3(fig7_qa_by_type) 在纯文本 LLM(deepseek-chat) 下, 以验证集前 150 个带定位标注的问题对比第三章的两种智能体设计: 单循环函数调用智能体 (W4), 与 LangGraph 状态机 (W7)——后者增加了时序工具 (get_segments_around) 与一个有界的自我反思环节, 在接受答案前将草稿的引用与已收集证据比对审计。

表 5.4 —— 五选一 QA 准确率, 150 个验证集问题 (纯文本 LLM)。

智能体	总体	CW (n=61)	TN (n=44)	TC (n=22)	CH (n=21)
简单循环 (W4)	.447	.459	.341	.591	.429
LangGraph (W7)	.547	.590	.341	.773	.619

两个智能体都远超 .20 的随机下限, 确认检索到的转写证据携带可用信号。图智能体将总体准确率提高 10 个百分点 (相对 +22%), 增益集中于因果类 (CW +13.1、CH +19.0 个百分




图 5.3: 不同问题类型与智能体配置下的问答准确率。

点) 与时序当下类 (TC +18.2)。轨迹检视将增益归于三种行为: 时序问题上系统性的”先锚定、再游走”检索; 初始证据单薄时改写措辞的追加搜索; 以及反思环节——在被观察的运行中, 它驳回过引用不存在于所收集证据中的草稿, 迫使其有据重写。

醒目的例外是 TN(接下来发生了什么), 两个智能体都冻结在.341。定性检视显示时序机制完全按设计工作——智能体锚定了线索事件、也取回了其后的片段——却在最后一步失败:TN 问题的答案几乎总是一个视觉动作 (人或动物接下来做了什么), 其后的片段通常无人说话, 纯文本 LLM 得不到任何可用证据。在一个代表性案例中 (“白狗走到垫子旁之后做了什么”, 真值为嗅那只黑狗), 纯文本智能体回答说锚点之后的片段没有语音、该动作”无法从可用证据中判断”——对其自身证据饥饿的一次准确自述。

5.4.2 对照实验: 回答阶段的视觉证据

TN 的结果给出一个精确的假设: 瓶颈在证据通道, 而非时序机制。为检验它, 同样的 44 个 TN 问题在仅改动一处的条件下重跑: 供应商切换为多模态 LLM(claude-opus-4-8), 其工具结果在转写旁嵌入每个片段的关键帧图像。检索索引、工具、提示词与问题全部保持不变。

表 5.5 ——同一批 44 个 TN 问题, 仅变动证据通道。

配置	TN 准确率
纯文本 LLM, 简单智能体	.341
纯文本 LLM, 图智能体 (时序工具)	.341
多模态 LLM, 关键帧入证据	.636

准确率上升 29.5 个百分点 (相对 +87%, 44/44 题全部完成)。在上述代表性案例中, 多模态智能体回答“俯身嗅闻/轻蹭躺在垫子里的黑色小狗 [28–36 s]”——仅凭关键帧便与真值几乎逐字吻合; 图 5.4(fig8_whitedog_case) 将涉事关键帧与两个模型的原文回答并列展示。由于除证据模态外一切保持恒定, 这一提升可归因于回答阶段的视觉证据。与 §5.2 合观, 模态问题在流水线两端的回路就此闭合: 检索需要视觉嵌入才能找到正确时刻, 生成需要视觉证据才能描述它。




图 5.4: 白狗案例: 检索关键帧及纯文本与视觉证据条件下的回答。

5.4.3 如何解读.341 的地板

对纯文本 TN 地板的两种解读需要分开。高出随机的.14 中, 一部分反映真实的转写证据; 另一部分很可能反映 NExT-QA 的答案先验——语言模型有时无需证据即可排除不合理的干扰项。对照实验为该效应划定了边界: 无论.341 中有多大比例源于先验, 来自关键帧的额外.295 都与先验无关, 因为两个条件下先验完全相同。一个更完整的“仅先验”基线 (不给任何工具直接作答) 留待未来工作。

5.5 系统级测量

离线阶段在单块 RTX 4050 笔记本 GPU(6 GB) 上约 2 小时处理完全部 567 个视频: 关键帧抽取每视频不足 1 秒, Whisper large-v3(int8, CTranslate2) 转写每视频 2–20 秒; CLIP ViT-B-32 对 5,725 个片段的嵌入与建索引另需约 15 分钟, SigLIP 索引约 35 分钟。所得索引可携带 (每骨干 npz 形式约 17 MB 向量外加 ChromaDB 存储), 查询为交互级速度: 问题编码在 GPU 上亚秒完成, 5,725 向量上的 HNSW 检索为毫秒级, 视觉重排只增加一次对 30 个候选的批量矩阵乘。端到端的智能体回答依工具轮数需 15–60 秒, 主导项是 LLM 延迟。边际 API 成本很小: 整个验证集的查询分解约 0.15 美元 (此后缓存复用), 150 题纯文本 QA 约 0.35 美元, 44 题多模态运行约 3 美元。本章的完整评估套件可在一台消费级笔记本加约 5 美元 API 用量内复现。

5.6 小结

就 RQ1: 多模态 (视觉) 检索在全库范围以一个数量级超越纯文本基线, corpus/video 的差距将主导误差定位为跨视频混淆。就 RQ2: 消融表明 (i) 朴素后期融合在任何权重下都救不了弱文本通道; (ii) 查询分解买到深排名召回、视觉重排买到头部精度, 且二者可组合; (iii) SigLIP 是最强的索引骨干, 使基线 R@1 接近翻倍; (iv) 廉价索引/昂贵重排的两阶段设计与昂贵索引正面打平。就 RQ3: 带时序工具与自我反思的 LangGraph 智能体较单循环智能体提升 QA 准确率 10 个百分点; 证据通道对照实验显示视觉证据使时序后续类准确率接近翻倍——确立了模态在回答阶段独立于检索阶段的作用。第六章讨论这些发现的局限与普适性。

第六章 讨论

6.1 综合: 三个可分离的问题

第五章最清晰的启示是: 视频 RAG 系统的端到端失败可分解为三个可分离的问题——它们成因不同、对应的干预不同, 且各干预可以组合。

第一个是召回问题: 正确时刻根本没有进入候选池, 因为查询以因果或时序语言表述, 而对比式视觉-语言编码器无法将其与像素匹配。查询分解针对的恰是它——把问题改写为场景描述使深排名召回上升 (全库 $R@10$ 相对 +10%), 而头名不动 (§5.3.2)。第二个是精排问题: 正确时刻已在候选池中, 但近乎并列的余弦分数无法把它排到第一。用更强视觉模型做第二级重打分解决的是它、且只解决它 (§5.3.3); 整体更换索引骨干亦然 (§5.3.4)。第三个是证据问题: 正确时刻已被检索、时间戳无误、摆在了回答者面前——而回答者无法作答, 因为决定性证据是视觉的、它的输入却是文本。任何检索改进都治不了这一层; 更换证据通道可以 (时序后续类 +87%, §5.4.2)。

以这种方式解读结果, 解释了各干预为何以可加而非相互蚕食的方式组合 (表 5.2): 每项干预移除的是不同的瓶颈。它也为从业者给出一份诊断配方: 对比 corpus 与 video 范围以分离跨视频混淆与定位误差; 对比浅层与深层召回以分离召回与精排问题; 对比纯文本与多模态回答以暴露证据饥饿。

值得单独抽出的第二条线索是: 模态的价值取决于角色, 而非绝对。转写通道作为检索键两度失败——作为嵌入 (§5.2) 与作为交叉编码器信号 (§5.3.3)——然而同样的转写, 作为证据交给回答 LLM 时, 支撑起远高于随机下限的 QA 准确率 (总体 .547), 并明显扛起了因果类问题——其中超出随机的部分不可能全部来自先验。日常视频中的语音对“事情发生在哪里”是糟糕的指针, 但一旦找对了时刻, 它仍能部分描述“发生了什么”。以单一数字报告某模态“贡献”的消融把这两种角色混为一谈; 我们的结果表明二者应当分开度量。

最后, 两阶段等价性结果 (§5.3.4) 有超出本项目的架构含义。在 5,725 个片段的规模上, 用昂贵模型做索引不足挂齿, 而廉价索引/昂贵重排的两阶段设计已经在测量噪声内追平了它。由于重排成本固定 (每查询 top-30) 而索引成本随语料线性增长, 两阶段设计是二者中唯一能在扩展中存活的——而本工作提供的证据是: 质量上的牺牲可以为零。

6.2 局限

单一基准、单一领域。全部结论取自 NExT-QA/GQA: 简短、日常、语音稀疏的家庭视频。关于文本通道的负结果——融合无益 (§5.3.1)、文本交叉编码器有害 (§5.3.3)——最好读作以此领域为条件。在语音密集、单一语言的领域 (讲座、会议、新闻), 转写的信息量大得多, 同样的组件很可能反号。正结果 (分解、视觉重排、骨干排序、证据通道效应) 依赖的是对比式编码器与 QA 任务的性质而非这份语料, 应更易迁移; 在第二个基准上验证这一点是本职工作最直接的延伸。

文本通道结果内部的混淆变量。弱文本通道有两个纠缠的成因: 转写常常无信息 (与问题无关的闲聊), 又常常不可读 (多语言语音对上以英语为主的 CLIP 文本编码器)。现有实验无法在二者之间分摊责任。一个“先翻译再嵌入”的变体——建索引前将全部转写机器翻译为英语——能以低成本将其分离, 未做仅因时间。

分段粒度为时序精度设置上限。片段是 4 秒步长上的固定 8 秒窗口, 而真值区间长度自由; 即使完美的排序器也不可能超过对齐最好的窗口所能达到的 tIoU。§5.3.5 中 $\tau = 0.5$ 与 $\tau = 0.3$ 结果的落差, 部分是这种量化误差而非排序误差。因此 tIoU@1 携带一个属于分段器的结构性天花板; 自适应或镜头对齐的分段能抬高天花板本身。

多项选择准确率是代理指标。NExT-QA 的五选一格式带来廉价、客观的评分, 但它度量的是答案选择而非答案质量: 生成文本的忠实度与时间戳引用的正确性, 只由智能体自身的反思环节审计, 未经人工或 LLM 评审的系统评估。白狗案例 (§5.4.2) 说明生成的答案可以精确且有据, 但本文未进行系统性的开放式答案评估。

样本量与单次运行。检索结果覆盖全部 3,358 个问题, 且在冻结的分解缓存下是确定性的。QA 实验则受预算限制: 智能体对比 150 题, 视觉对照实验 44 题, 文本交叉编码器在 100 题开发子集上被否决。全部智能体数字是非确定性 API 模型的单次运行, 无置信区间; 报告的效应 (总体 +10 个百分点、TN +29.5 个百分点) 相对可信的方差幅度足够大, 但表 5.4 按题型各列中的小差异 ($n \leq 22$) 不应被过度解读。

智能体对比中的不对称。LangGraph 智能体目前仅支持 OpenAI 兼容供应商, 因此视觉对照实验是在简单智能体下运行的; 观察到的最强配置 (多模态证据) 与最强智能体 (图) 从未组合, 故.636 的 TN 结果很可能是下界而非上界。对称地, 图智能体的反思环节与多模态通道可能存在交互 (例如反思可以审计视觉论断), 同样未经检验。

没有用户研究。项目计划排了一个小型用户研究 (W10); 它被让位于视觉对照实验与消融矩阵——我们判断后者单位时间产出的可辩护证据更多。Streamlit 演示 (§3.6) 可作定性替代, 但关于终端用户效用的论断仍无支撑, 本文有意不作此类论断。

6.3 效度威胁

构念效度。命中判据 (视频正确且 $\text{fIoU} \geq \tau$) 严于既有文献常用的视频级检索指标; 这压低了与该文献相比的绝对数字, 却忠实于时刻检索这一构念。QA 方面, 多项选择格式允许答案先验效应: 语言模型可以不凭证据排除不合理的干扰项。对照实验为此划界——两个证据条件下先验完全相同, 故 +29.5 个百分点的效应不可能由先验驱动——但纯文本³⁴¹的绝对值中先验与证据的比例未知; 一个不做检索的“仅先验”基线可补全图景。

内部效度。分解缓存在所有使用它的配置间逐字共享, 消除了这些比较中的分解方差。重排器的融合权重 (0.5) 与候选池 (30) 为事前固定而非调优; 用于否决文本交叉编码器的开发子集 ($n = 100$) 与完整评估集在用途上分离、在题目上不相交并不成立——但由于它支撑的决定是排除一个组件, 任何偏差方向都是保守的。智能体实验的分解与作答调用了同一 LLM 家族 (DeepSeek), 原则上可能使其误差相关; 检索实验不受影响, 因为分解质量在全部检索配置间恒同。

外部效度。除上述领域局限外, 还有两条规模上的限定。语料 (567 视频、5,725 片段) 小到 HNSW 检索实际等同精确检索; 数百万片段规模下 ANN 召回的退化未被测量。两阶段等价性主张是在两种设计都可行的规模上演示的——它向大语料的外推依赖 §6.1 的论证而非直接测量。最后, 全部基于 API 的结果绑定于无版本号的商用模型端点 (deepseek-chat、claude-opus-4-8, 2026 年年中); 已提交的提示词、缓存与结果文件使分析可审计, 但智能体运行的逐位复现无法由供应商保证。

6.4 小结

这些发现凝聚为一个叙事: 在日常视频中, 凡存在模态选择之处, 视觉信号在每一阶段都占优; 剩余误差可分离为召回、精排与证据三类问题, 各有独立且可组合的解法。主要局限——单一领域、代理性的 QA 指标、预算受限的智能体样本、未经检验的“图智能体 + 视觉”组合——都是加算力即可解决的, 无需新机制; 且没有任何一条威胁到所报告效应的方向, 其幅度 (骨干带来相对 +69% 的 $R@1$ 、证据通道带来 +87%) 远超可信的噪声下限。第七章总结全文并给出对应的未来工作。

第七章 结论与未来工作

7.1 对研究问题的回答

RQ1 ——相对纯文本基线的检索效果。在日常视频上, 以视觉嵌入检索的多模态流水线在时刻粒度上以一个数量级超越基于转写的检索 (全库范围 $R@10$ 为 .111 对 .011, $tIoU \geq 0.5$); 而充分发展后的系统——SigLIP 索引加 LLM 查询分解——又使最初的视觉基线接近翻倍 ($R@1$.026 $\rightarrow$.048; video 范围 $tIoU@1$.230)。范围分析将剩余困难归于跨视频混淆而非视频内定位: 给定正确视频, 在较宽松的 $\tau = 0.3$ 下, 系统为三分之二的问题把正确时刻排进前五 ($R@5$.677)。因此对 RQ1 的回答是肯定的, 但附带一个精确的警示: 视觉检索有效且可继续改进; 而检索“说了什么”, 在这一领域与其说是可行基线, 不如说是一则警世寓言。

RQ2 ——多模态嵌入策略。实验支撑的是一套策略而不止是一个排名: 用可负担的最强对比式骨干为视觉通道建索引 (SigLIP SO400M 全面压过两个 CLIP 变体, 作为索引带来相对 +69% 的 $R@1$); 若最强骨干在语料规模上不可负担, 则廉价建索引、再用强模型对其头部候选重排——这与昂贵索引的差距在测量噪声之内; 通过 LLM 分解把问题翻译进编码器的原生语域 (场景描述) 以获得深排名召回; 并且不要以任何权重融入弱文本通道、也不要文本交叉编码器重排——两者都会以一个已识别的成因 (稀疏、多语言、闲聊式语音) 降低质量。在本基准上, 音频与屏幕文字的最优策略是空策略; 第六章标出了这一结论应当被重检的领域。

RQ3 ——智能体式分解与合成。查询分解、时序工具使用与有界自我反思各自都有可证实的贡献。在检索层, 分解具有构造上的安全性 (原始查询始终保留) 并提升召回。在回答层, 一个锚定事件、沿时间轴游走、并审计自身引用的 LangGraph 状态机, 将五选一 QA 准确率从 .447 提升到 .547, 增益最大处在因果与时序当下类问题。证据通道对照实验补全了答案: 智能体机制无法弥补模型感知不到的证据——在其余一切保持不变的条件下, 向回答者提供关键帧使时序后续类准确率接近翻倍 (.341 $\rightarrow$.636)。因此, 一个有效的视频问答智能体同时是一个检索规划器与一个多模态阅读器; 缺了任何一半, 另一半的上升空间都无法兑现。

7.2 未来工作

六个方向直接源自第六章识别的局限,大致按“单位投入的证据产出”排序。

修复文本通道,然后重测融合。建索引前将转写机器翻译为英语(或改用多语言文本检索编码器),解开 §6.2 的“无信息/不可读”混淆变量——然后才重访后期融合与文本重排,它们的负结果是以损坏的通道为条件的。

将图智能体与多模态证据组合。最强的智能体与最强的证据通道从未同场;把 LangGraph 框架扩展到 Anthropic API(或具备视觉能力的开源模型),既检验反思能否审计视觉论断,也回答 TN 的天花板能越过.636 多远。

完成开源模型对比。供应商抽象已支持任意 OpenAI 兼容端点;对本地 Qwen/Llama 模型运行 QA 套件(管道与评估脚本俱在)将量化项目计划所预期的“API 对开源”的取舍。

仅先验的 QA 基线。不给任何工具、直接回答多项选择题,可为全部 QA 数字中的答案先验成分划界 (§6.3),以可忽略的成本锐化每一次智能体对比。

自适应分段。固定的 8 秒窗口为 tIoU 施加结构性天花板 (§6.2);镜头对齐或查询自适应的窗口能抬高天花板本身,且现有评估框架可直接度量收益。

第二领域与用户研究。在语音密集的视频(讲座、会议)上复现模态消融,检验第六章的条件性论断;而被移出范围的用户研究,仍是支撑任何离线指标都无法支撑的终端用户效用论断的正确工具。

7.3 结语

本项目的出发点,是在“每个设计选择都必须被测量”的纪律下,让一段视频的某个时刻像一句文本一样可寻。其最有用的遗产或许不在头条数字,而在证据的形状:失败被分离为召回、精排与证据三类问题;负结果连同其成因被保留;流水线中的每个疗法都可以被打开、被关闭、被计价。视频理解系统仍将快速更迭;而一套能够回答“哪个部分起了作用、作用多大、为什么”的评估框架,才是可迁移的资产。

参考文献

- [1] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever. Learning transferable visual models from natural language supervision. *Proceedings of the 38th international conference on machine learning (ICML)*, 2021.
- [2] X. Zhai, B. Mustafa, A. Kolesnikov, and L. Beyer. Sigmoid loss for language image pre-training. *Proceedings of the IEEE/CVF international conference on computer vision (ICCV)*, 2023.
- [3] C. Schuhmann, R. Beaumont, R. Vencu, C. Gordon, R. Wightman, M. Cherti, T. Coombes, A. Katta, C. Mullis, M. Wortsman, and others. LAION-5B: An open large-scale dataset for training next generation image-text models. *Advances in neural information processing systems (NeurIPS) datasets and benchmarks track*, 2022.
- [4] M. Cherti, R. Beaumont, R. Wightman, M. Wortsman, G. Ilharco, C. Gordon, C. Schuhmann, L. Schmidt, and J. Jitsev. Reproducible scaling laws for contrastive language-image learning. *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition (CVPR)*, 2023.
- [5] J. Xiao, X. Shang, A. Yao, and T.-S. Chua. NExT-QA: Next phase of question-answering to explaining temporal actions. *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition (CVPR)*, 2021.
- [6] J. Xiao, A. Yao, Y. Li, and T.-S. Chua. Can I trust your answer? Visually grounded video question answering. *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition (CVPR)*, 2024.
- [7] J. Xu, T. Mei, T. Yao, and Y. Rui. MSR-VTT: A large video description dataset for bridging video and language. *Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR)*, 2016.
- [8] R. Krishna, K. Hata, F. Ren, L. Fei-Fei, and J. C. Niebles. Dense-captioning events in videos. *Proceedings of the IEEE international conference on computer vision (ICCV)*, 2017.
- [9] J. Gao, C. Sun, Z. Yang, and R. Nevatia. TALL: Temporal activity localization via language query. *Proceedings of the IEEE international conference on computer vision (ICCV)*, 2017.
- [10] J. Lei, T. L. Berg, and M. Bansal. Detecting moments and highlights in videos via natural language queries. *Advances in neural information processing systems (NeurIPS)*, 2021.

- [11] H. Luo, L. Ji, M. Zhong, Y. Chen, W. Lei, N. Duan, and T. Li. CLIP4Clip: An empirical study of CLIP for end-to-end video clip retrieval and captioning. *Neurocomputing*, 508, pp. 293–304, 2022.
- [12] S. Yu, J. Cho, P. Yadav, and M. Bansal. Self-chained image-language model for video localization and question answering. *Advances in neural information processing systems (NeurIPS)*, 2023.
- [13] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever. Robust speech recognition via large-scale weak supervision. *Proceedings of the 40th international conference on machine learning (ICML)*, 2023.
- [14] Y. A. Malkov and D. A. Yashunin. Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 42 (4), pp. 824–836, 2020.
- [15] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W. Yih, T. Rocktäschel, S. Riedel, and D. Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in neural information processing systems (NeurIPS)*, 2020.
- [16] K. Guu, K. Lee, Z. Tung, P. Pasupat, and M.-W. Chang. REALM: Retrieval-augmented language model pre-training. *Proceedings of the 37th international conference on machine learning (ICML)*, 2020.
- [17] V. Karpukhin, B. Oğuz, S. Min, P. Lewis, L. Wu, S. Edunov, D. Chen, and W. Yih. Dense passage retrieval for open-domain question answering. *Proceedings of the 2020 conference on empirical methods in natural language processing (EMNLP)*, 2020.
- [18] L. Gao, X. Ma, J. Lin, and J. Callan. Precise zero-shot dense retrieval without relevance labels. *Proceedings of the 61st annual meeting of the association for computational linguistics (ACL)*, 2023.
- [19] G. V. Cormack, C. L. A. Clarke, and S. Buettcher. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. *Proceedings of the 32nd international ACM SIGIR conference on research and development in information retrieval*, 2009.
- [20] R. Nogueira and K. Cho. Passage re-ranking with BERT. *arXiv preprint arXiv:1901.04085*, 2019.
- [21] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, and Z. Liu. BGE M3-Embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. *arXiv preprint arXiv:2402.03216*, 2024.
- [22] A. Asai, Z. Wu, Y. Wang, A. Sil, and H. Hajishirzi. Self-RAG: Learning to retrieve, generate, and critique through self-reflection. *Proceedings of the twelfth international conference on learning representations (ICLR)*, 2024.
- [23] J. Wei, X. Wang, D. Schuurmans, M. Bosma, B. Ichter, F. Xia, E. Chi, Q. V. Le, and D. Zhou. Chain-of-thought prompting elicits reasoning in large language models. *Advances in neural information processing systems (NeurIPS)*, 2022.

- [24] S. Yao, J. Zhao, D. Yu, N. Du, I. Shafran, K. Narasimhan, and Y. Cao. ReAct: Synergizing reasoning and acting in language models. *Proceedings of the eleventh international conference on learning representations (ICLR)*, 2023.
- [25] D. Zhou, N. Schärli, L. Hou, J. Wei, N. Scales, X. Wang, D. Schuurmans, C. Cui, O. Bousquet, Q. V. Le, and E. H. Chi. Least-to-most prompting enables complex reasoning in large language models. *Proceedings of the eleventh international conference on learning representations (ICLR)*, 2023.
- [26] T. Schick, J. Dwivedi-Yu, R. Dessì, R. Raileanu, M. Lomeli, E. Hambro, L. Zettlemoyer, N. Cancedda, and T. Scialom. Toolformer: Language models can teach themselves to use tools. *Advances in neural information processing systems (NeurIPS)*, 2023.
- [27] N. Shinn, F. Cassano, A. Gopinath, K. Narasimhan, and S. Yao. Reflexion: Language agents with verbal reinforcement learning. *Advances in neural information processing systems (NeurIPS)*, 2023.
- [28] X. Wang, Y. Zhang, O. Zohar, and S. Yeung-Levy. VideoAgent: Long-form video understanding with large language model as agent. *Proceedings of the european conference on computer vision (ECCV)*, 2024.
- [29] Y. Fan, X. Ma, R. Wu, Y. Du, J. Li, Z. Gao, and Q. Li. VideoAgent: A memory-augmented multimodal agent for video understanding. *Proceedings of the european conference on computer vision (ECCV)*, 2024.
- [30] C. Zhang, T. Lu, M. M. Islam, Z. Wang, S. Yu, M. Bansal, and G. Bertasius. A simple LLM framework for long-range video question-answering. *Proceedings of the 2024 conference on empirical methods in natural language processing (EMNLP)*, 2024.
- [31] X. Ren, L. Xu, L. Xia, S. Wang, D. Yin, and C. Huang. VideoRAG: Retrieval-augmented generation with extreme long-context videos. *arXiv preprint arXiv:2502.01549*, 2025.
- [32] DeepSeek-AI. DeepSeek-V3 technical report. *arXiv preprint arXiv:2412.19437*, 2024.